



Exploratory Data Analysis of Factors Associated with Heart Disease

Reza Ebrahimzadeh

Exploratory Data Analysis (EDA)

for Noyanlearn

28 august 2026

Version 1.1

Tools & Technologies:

Python · Pandas · Matplotlib · Seaborn · Jupyter Notebook

فهرست مطالب

3	 خلاصه ی اجرایی
4	 مقدمه
5	 مجموعه داده
6	 شناخت داده
6	 نوع داده ها
7	 مقادیر گمشده و داده های تکراری
	 تحلیل اکتشافی داده ها:
8	 تحلیل تک متغیره
14	 تحلیل دو متغیره
18	 تحلیل چند متغیره
28	 یافته ها
29	 سایر توضیحات
30	 محدودیت ها
31	 نتیجه گیری
32	 منابع

خلاصه ی اجرایی

هدف این پروژه، بررسی الگوها و روابط موجود در یک مجموعه داده مربوط به بیماری قلبی و شناسایی ویژگی‌هایی است که بیشترین ارتباط را با ابتلا به بیماری قلبی دارند.

در این تحلیل، ابتدا ساختار داده‌ها، نوع متغیرها، مقادیر گمشده و داده‌های تکراری بررسی و سپس تحلیل‌های تک‌متغیره، دو متغیره و چندمتغیره انجام شد. برای نمایش بهتر الگوهای موجود در داده از نمودارهایی مانند Bar Plot، Histogram، Box Plot، Count Plot و برای تحلیل‌های چندمتغیره از نمودارهای Scatter و Heatmap استفاده شد.

الگوهای متفاوتی در متغیرهایی مانند جنسیت، کلاسترول و سن، در میان گروه‌های دارای بیماری و فاقد بیماری مشاهده شد. همچنین بررسی همزمان چند متغیر نشان داد که ترکیب ویژگی‌ها می‌تواند نسبت به بررسی جداگانه هر ویژگی، اطلاعات بیشتری درباره الگوهای بیماری ارائه کند.

با این حال، نتایج این تحلیل به معنای رابطه علت و معلولی نیستند و برای نتیجه‌گیری پزشکی قطعی به داده‌های بیشتر و روش‌های آماری و بالینی مناسب نیاز است.

مقدمه

بیماری‌های قلبی از مهم‌ترین مشکلات سلامت در جهان هستند؛ یکی از کاربردهای تحلیل داده در این حوزه، بررسی ویژگی‌های افراد و شناسایی الگوهایی است که با وجود بیماری قلبی ارتباط دارند.

در این پروژه تلاش کردم با استفاده از روش تحلیل اکتشافی داده‌ها (EDA)، ساختار داده را بررسی کنم و رابطه میان ویژگی‌های مختلف و متغیر هدف target را مورد مطالعه قرار بدم.

- سؤال اصلی پروژه این است:

چه الگوها و روابطی میان ویژگی‌های افراد و وجود بیماری قلبی در این مجموعه داده مشاهده می‌شود؟

مجموعه داده

داده ی استفاده شده، شامل اطلاعات تعدادی از افراد و ویژگی‌های مرتبط با شرایط فیزیکی و وضعیت قلبی آنها است. متغیرهایی که در آن پروژه مورد بررسی قرار گرفتند، عبارت‌اند از:

ویژگی	نوع	توضیحات
سن فرد (age)	عددی	سن فرد
جنسیت (sex)	دسته بندی	جنسیت فرد
نوع درد قفسه ی سینه (cp)	دسته بندی	درد معمول قلبی (Typical Angina): درد قفسه سینه‌ای که شبیه درد معمول قلبی است؛ مثلاً هنگام فعالیت یا فشار ایجاد می‌شود و با استراحت بهتر می‌شود. درد غیر معمول قلبی (Atypical Angina): درد قفسه سینه‌ای که شبیه درد قلبی هست، ولی الگوی کاملاً معمول را ندارد. درد غیر قلبی (Non-anginal Pain): فرد درد قفسه سینه دارد، اما درد احتمالاً مربوط به قلب و آنژین نیست؛ مثلاً ممکن است عضلانی یا گوارشی باشد. بدون درد/علامت (Asymptomatic): فرد درد قفسه سینه ندارد یا علامت مشخصی از درد قفسه سینه گزارش نمی‌کند.
فشار خون (trestbps)	عددی	فشار خون در زمان استراحت
میزان کلسترول (chol)	عددی	میزان کلسترول خون
آنژین بعد از تست (exang)	دسته بندی	وجود آنژین قلبی بعد از تست
وجود بیماری (target)	دسته بندی	وضعیت وجود بیماری قلبی متغیر target به‌عنوان Target Variable در نظر گرفته شده است.

شناخت داده

در ابتدا تعداد ردیف‌ها و ستون‌های مجموعه داده شامل 1025 رکورد و 14 ویژگی است.

بنابراین هر ردیف نماینده اطلاعات یک فرد و هر ستون نماینده یک ویژگی از آن فرد است.

- ویژگی‌های موجود شامل متغیرهای عددی و دسته‌ای هستند.

متغیرهای عددی		سن فرد		فشار خون		میزان کلسترول			
متغیرهای دسته بندی		جنسیت		نوع درد قفسه ی سینه		آنژین بعد از تست		وجود بیماری	

نوع داده‌ها

بررسی نوع داده‌ها نشان داد که همه ی متغیرها به صورت عددی ذخیره شده‌اند؛ با این حال، عدد بودن رکورد های یک ستون لزوماً به معنای numeric بودن آن نیست.

برای مثال، cp به صورت عددی ذخیره شده است اما در واقع یک متغیر دسته‌ای است که انواع مختلف درد قفسه سینه را نمایش می‌دهد.

بنابراین در تحلیل cp از روش‌های مناسب داده‌های دسته‌ای استفاده شد.

مقادیر گمشده و داده‌های تکراری

بررسی نشان داد که مجموعه داده هیچ داده ی گمشده ای نداشت است بنابراین نیازی به پردازش داده های گمشده نبود.

در بررسی داده‌های تکراری، 723 رکورد تکراری بر اساس مقادیر تمام ستون‌ها شناسایی شد. پس از حذف رکوردهای تکراری، 302 رکورد باقی ماند. از آنجا که بخش قابل توجهی از داده‌ها تکراری بودند، حذف آنها می‌تواند بر توزیع داده و نتایج تحلیل اثرگذار باشد. بنابراین این موضوع به‌عنوان یکی از محدودیت‌های تحلیل در نظر گرفته شد. در این پروژه هدف اصلی تحلیل اکتشافی است؛ بنابراین تمرکز اصلی روی شناخت داده و روابط بین متغیرها قرار گرفت.





همچنین متغیرهای دسته‌ای که به صورت عددی کدگذاری شده‌اند، هنگام تحلیل به عنوان متغیرهای categorical در نظر گرفته شد.

تحلیل اکتشافی داده ها

❖ تحلیل تک متغیره

(1) افراد دارای بیماری قلبی



توازن نسبی بین افراد سالم و افراد مبتلا به بیماری قلبی وجود دارد (اختلاف حدودا 10 درصدی که مبتلایان بیشتر هستند) که این موضوع باعث میشود تا در تحلیل تاثیر ویژگی های مختلف روی بیماری قلبی، به نتایج متنوعی دست پیدا کنیم.



(2) سن

توزیع سن نشان می دهد که اغلب افراد مجموعه در محدوده ی میانسال قرار گرفته اند(48 تا 61 سال). بررسی این متغیر در مراحل بعدی می تواند مشخص کند که آیا توزیع سن دارای بیماری قلبی و فاقد بیماری متفاوت است یا خیر.

(3) جنسیت





توزیع جنسیت افراد مجموعه این موضوع را نشان میدهد که مردها به صورت ملموسی سهم بیشتری را سپیم هستند (بیش از 2 برابر در تعداد).

این موضوع باعث می شود تا برای تحلیل های چندگانه ی ویژگی ها، برای جنسیت از درصد استفاده کنیم تا تحلیل واقعگرایانه تری داشته باشیم. هرچند تعداد کمتر خانم ها در مجموعه باعث میشود تا کیفیت تحلیل آنها همراه با سایر ویژگی ها کمی کمتر از آقایان باشد. تعداد کمتر نمونه های زنان می تواند باعث افزایش عدم قطعیت در برآورد درصدها و کاهش قابلیت تعمیم نتایج این زیرگروه شود.


البته من در این پروژه سعی کردم تا جای ممکن این موضوع را پوشش دهم.

(4) نوع درد قفسه ی سینه




بررسی نشان میدهد که نزدیک نیمی از افراد حاضر در مجموعه درد معمول قلبی را گزارش کرده اند. اختلاف قابل توجهی بین تعداد گزارش های این نوع درد نسبت به سایر درد ها وجود دارد. این موضوع میتواند احتمال اینکه بیشتر افراد مبتلا دارای این ویژگی باشند را بالا می برد اما قطعی نیست. بیش از یک چهارم افراد درد غیر آنژینی را گزارش کرده اند و کمتر یک چهارم گزارش ها مربوط به افرادی بود که درد تپیک قلبی دارند یا افرادی است کلا دردی را گزارش نکردند.

(5) فشار خون در زمان استراحت





اغلب افراد مجموعه در بازه ی بیش از 120 میلی متر حیوه از فشار خون سیستولیک قرار دارند که نشان دهنده ی تاثیر بالای این پارامتر در این پروژه است. حدود 80 درصد از افراد حاضر در مجموعه، در این محدوده از فشار خون قرار دارند.

(6) میزان کلسترول خون



بیشتر افراد در محدوده ی کلسترول بیش از 200 میلی گرم در دسی لیتر قرار دارند. که چارک اول و سوم نشان دهنده ی این موضوع است. نزدیک 84 درصد افراد، در این محدوده قرار دارند.

(7) آنژین ناشی از ورزش





توزیع و تقسیم نمودار نشان میدهد که افراد بدون آنژین بعد از تست ورزش، تقریباً دو برابر افراد دارای آنژین هستند.

❖ تحلیل دو متغیره

(1) سن و بیماری


توزیع بر اساس سن نشان می‌دهد که تعداد افراد مبتلا در بازه سنی حدود ۴۰ تا ۶۰ سال بیشتر مشاهده شده است. بیشترین تعداد موارد بیماری در محدوده سنی ۵۰ تا ۶۰ سال دیده می‌شود. با این حال، از آنجا که نمودار بر اساس تعداد رسم شده است، این الگو به تنهایی به معنی افزایش نرخ یا احتمال ابتلا با افزایش سن نیست و برای بررسی دقیق‌تر، مقایسه درصد ابتلا در گروه‌های سنی می‌تواند مناسب‌تر باشد.



(2) جنسیت و بیماری

نتیجه‌ی بررسی در نمودار نشان می‌دهد که درصد بیشتری از خانم‌ها نسبت به آقایان جزو مبتلایان بوده‌اند. هر چند چون جامعه‌ی آماری خانم‌ها در این مجموعه داده کوچک‌تر از آقایان است، پس نمیتوان به طور قطعی گفت که خانم‌ها همواره بیشتر در خطر هستند و از طرفی بررسی سایر پارامترها نیز در اولویت قرار دارد تا از این دیدگاه کورکورانه جلوگیری شود.

(3) نوع درد قفسه ی سینه و بیماری



کمترین میزان ابتلا متعلق به درد تیپیک قلبی است. درد غیر آنژینی که دارای الگوی غیر مشخص است بیشترین گزارش برای ابتلا به بیماری قلبی (۸۰ درصد) را ثبت کرده است که دور از ذهن هم نبود. اما نکته ی خطرناک در دسته بندی برای درد های غیر آنژینی و افراد بدون علامت است که آمار حدود ۷۰ درصدی برای ابتلا گزارش شده. این نشان میدهد که نوع درد نباید گول زننده باشد و حتی افراد بدون علامت هم میتوانند کاندید ابتلا به بیماری قلبی باشند. پس بررسی یک عامل مثل نوع درد قفسه ی سینه، و نتیجه گیری سریع، به شدت پرریسک محسوب میشود و کافی نیست. از این رو باید سایر عوامل را نیز در نظر گرفت.


(4) فشار خون و بیماری

بررسی این را مشخص کرد که بعد از حداکثر فشار خون نرمال (۱۲۰ میلی متر جیوه)

تعداد موارد مثبت در این محدوده بیشتر مشاهده می شود. اما این افزایش یکنواخت نیست

پس نمی توان فشارخون بالاتر را به تنهایی به عنوان شاخصی برای افزایش نرخ بیماری در این

داده در نظر گرفت.




(5) میزان کلسترول و بیماری

در کلسترول خون هم شرایط مشابه فشار خون است. در این داده مقادیر بالاتر کلسترول،


با افزایش مشاهده موارد مبتلا به بیماری قلبی همراه بود و بعد از حداکثر کلسترول نرمال

خون (در حدود ۲۰۰ میلی گرم در دسی لیتر) میزان ابتلا جهش قابل توجهی را طی کرده است.

این موضوع نشان میدهد که پارامتر کلسترول خون به شدت حائز اهمیت است.




(6) آنژین ناشی از ورزش و بیماری



اینجا در آمار آنژین بعد از تست ورزش با نکات جالبی برخورد می کنیم. توزیع ها نشان می دهند که اغلب مبتلایان به بیماری قلبی، فاقد درد آنژینی هستند. این نکته باعث می شود تا متوجه شویم که تحلیل این مورد به تنهایی کافی نیست و نمی تواند دلیل محکمی برای پیش بینی وجود بیماری باشد. پس باید این پارامتر را با دیگر ویژگی ها بررسی کرد تا به نکات بهتری دست پیدا کرد.


❖ تحلیل چند متغیره

(1) سن و جنسیت



در این نمودار پارامتر جنسیت تاثیر بیشتری دارد و خانم ها درصد بالاتری را برای بیماری به خود اختصاص داده اند. بازه ی سنی کمتر از ۴۵ سال بیشتر دچار ابتلا شده اند. برای خانم ها بازه ی سنی بیشتر از ۶۵ سال هم، سهم موارد ابتلا به بیماری، بیشتر گزارش شده است.


(2) سن و نوع درد قفسه ی سینه



نوع درد غیر تپیک در هر بازه ی سنی آمار ابتلای بالایی دارد. بیشترین آمار مربوط به افراد کمتر از ۴۵ سال است. دردهای غیر آنژینی در رتبه ی بعدی قرار دارد که باز در بازه ی سنی کمتر از ۴۵ سال بیشترین آمار ابتلا گزارش شده. درد تپیک کمترین گزارش ابتلا را دارد. افرادی که بدون علامت یا درد هستند در بازه ی سنی بیشتر از ۶۵ سال آمار بالایی از ابتلا را ثبت کرده اند. در مجموع بازه ی سنی زیر ۴۵ سال بیشترین تعداد مشاهده را دارد و تاثیر بیشتری را سهم است.


(3) جنسیت و نوع درد قفسه ی سینه

نمودار نشان میدهد که خانم در تمامی انواع درد آمار بیشتری را در ابتلا ثبت کرده اند. افراد بدون درد آنژینی و افراد بدون درد به ترتیب بیشترین آمار ابتلا را دارد که نشان میدهد این پارامتر به تنهایی به هیچ عنوان عامل موثر و تعیین کننده ای نمی باشد.




(4) جنسیت و آنژین ناشی از ورزش

افراد بدون درد در تست ورزش بیشترین گزارش را ثبت کرده اند. همچنین خانم ها در مجموع آمار بیشتری برای بیماری دارند. خانم هایی که بدون درد آنژینی بوده اند بیشترین آمار را ثبت کرده اند.




Disease Rate by Chest Pain Type and Exercise Induced Angina



(5) نوع درد قفسه ی سینه و آنژین ناشی از ورزش

مجدد عدم وجود درد بعد از تست، آمار بالاتری دارد. مخصوصا برای افرادی درد غیر تیپیک یا درد غیر آنژینی دارند. برای افرادی که درد آنژینی بعد از تست دارند، درد غیر تیپیک آمار بالاتری دارد به همراه افرادی که کلا دردی در قفسه ی سینه ندارند. در مجموع درد غیر تیپیک آمار بالاتری برای افراد مبتلا دارد.



Disease Rate by Age Group and Exercise Induced Angina



(6) سن و آنژین ناشی از ورزش

با توجه به نمودار می شود این تفسیر را انجام داد، افرادی که بدون درد آنژینی بعد از ورزش هستند آمار بالاتری را در تمامی بازه های سنی ثبت کرده اند. افراد کمتر از ۴۵ سال، در هر دو دسته ی درد بعد از تست یا بدون درد آنژینی بعد از تست، بیشترین گزارش ابتلا را دارند. بعد از افراد کمتر از ۴۵ سال، افراد بیش از ۶۵ سالی که درد آنژینی بعد از تست ندارند، آمار بالاتری برای بیماری را ثبت کرده اند.


7) سن و میزان کلسترول



افراد کمتر از ۴۵ سال با کلسترول بالا، آمار بالاتری برای بیماری را ثبت کرده اند. حتی با کلسترول نرمال هم باز آمار بالاتری را ثبت کرده اند. در افراد بیشتر از ۶۵ سال، افراد با کلسترول بالا یا نرمال، با توازن نسبتا بالایی، آمار بیماری را ثبت کرده اند.


با توجه به نمودار Scatter، افزایش ملموسی در تعداد موارد مبتلا به بیماری قلبی در محدوده ی بیشتر از ۲۰۰ مشاهده شد. محدوده سنی ۴۰ تا ۶۵ سالی که سطح کلسترول بالای ۲۰۰ را ثبت کرده اند، یک توده ی مشخصی از ابتلا به بیماری قلبی را ثبت کرده است.

(8) سن و فشار خون




افراد زیر ۴۵ سال با فشار خون، بیشترین آمار بیماری را ثبت کرده اند (۸۰ درصد). این بازه سنی حتی با فشار خون نرمال هم بالایی دارد. افراد بیشتر از ۶۵ سال هم با فشار خون نرمال، آمار بالایی را ثبت کرده اند که نشان میدهد در این بازه ی سنی، باید فاکتورهای دیگری را هم در نظر گرفت و نمی توان از روی فشار خون پایین برای تشخیص بیماری، تصمیم گیری کرد.

(9) میزان کلسترول و فشار خون



این دو پارامتر همبستگی پایین با هم دارند اما یک نکته که به چشم می خورد؛ آمار بیماری برای افرادی که کلسترول بالا و فشار خون نرمالی دارند، از بقیه ی دسته بندی ها بیشتر است.


10) سن، جنسیت و نوع درد قفسه‌ی سینه



برای آقایان بازه‌ی سنی زیر ۴۵ سال گزارش بیشتری ثبت شده. در این بازه، درد غیرتیپیک و افراد بدون درد آنژینی آمار بیشتری ثبت کرده‌اند. برای آقایان ۴۵ تا ۶۵ سال هم درد غیر تیپیک اما بالاتری را ثبت کرده است. برای آقایان بیشتر از ۶۵ سال، افراد بدون علامت بیشتر دارای بیماری بودند. در مجموع افراد بدون علامت و دارای درد غیرتیپیک در آقایان، به ترتیب آمار بالاتری را ثبت کرده‌اند.

برای خانم بازه‌ی سنی مثبت ۶۵ سال گزارش بیشتری ثبت شده است. در این بازه و بازه‌های دیگر، به جز درد تیپیک، بقیه‌ی نوع درد ها بیشترین آمار را ثبت کرده‌اند. برای آقایان ۴۵ تا ۶۵ سال هم درد غیر تیپیک آمار بالاتری را ثبت کرده است. در هر دو جنسیت، درد تیپیک کمترین آمار ابتلا را دارد.

11) سن، نوع درد سینه و آنژین بعد از تست ورزشی




برای افرادی که بعد از تست ورزشی دچار آنژین قلبی شده اند، بازه ی ۴۵ تا ۶۵ سال بیشترین آمار ابتلا را دارند. مخصوصاً افرادی که علامت یا درد خاصی ندارد یا درد غیر تیپیک دارند.

برای افرادی که بعد از تست ورزشی دچار آنژین قلبی نشده اند، افراد بیشتر از ۶۵ سال آمار بالایی برای بیماری دارند. در مرحله ی بعد افراد زیر ۴۵ سال آمار بالایی دارند. نوع درد غیر تیپیک در این دسته بندی، آمار بالایی دارد. در افراد کمتر از ۴۵ سال تا ۶۵ سال، درد غیر تیپیک و درد غیر آنژینی آمار بالایی برای ابتلا ثبت کرده اند. در افراد بیشتر از ۶۵ سال، درد غیر تیپیک و افراد بدون درد، آمار بالایی برای ابتلا ثبت کرده اند.

درد تیپیک قلبی کمترین میزان ابتلا را در هر بازه ی سنی و هر وضعیت بعد از تست ورزش را ثبت کرده است.


12) جنسیت، نوع درد قفسه ی سینه و آنژین ناشی از ورزش



آقایانی که بعد از تست ورزش دچار درد آنژینی شده اند و سابقه ی درد قبلی هم نداشتند بیشتر آمار ابتلا ثبت کرده اند. همچنین آقایانی که درد آنژینی بعد از تست را تجربه نکرده اند و سابقه ی درد غیر تیپیک را داشته اند، در مرحله ی بعد بیشترین آمار ثبت را دارند.

در خانم ها، افرادی که بعد از تست ورزش دچار درد آنژینی شده اند و سابقه ی درد غیر تیپیک یا درد غیر آنژینی داشته اند بیشتر آمار ابتلا ثبت کرده اند. همچنین خانم هایی که درد آنژینی بعد از تست را تجربه نکرده اند، در تمامی انواع درد سینه آمار بالایی در ثبت بیماری را رقم زده اند و سابقه ی درد غیر آنژینی یا بدون سابقه ی درد بودند، در مرحله ی بعد بیشترین آمار ثبت را دارند.

13) جنسیت، سن و آنژین ناشی از ورزش





در آقایانی که درد آنژینی بعد از تست داشته اند، همواره آمار پایینی در ثبت بیماری را نسبت به افراد بدون درد بعد از تست، داشته اند. آقایانی که درد آنژینی بعد از تست نداشتند و کمتر از ۴۵ سال بودند، آمار بالاتری برای ثبت دارند. همواره با افزایش سن، این آمار کاهش میابد.

در خانم ها هم مشابه آقایان، افرادی که درد آنژینی بعد از تست داشته اند، همواره آمار پایینی در ثبت بیماری را نسبت به افراد بدون درد بعد از تست، داشته اند. خانم هایی که درد آنژینی بعد از تست را تجربه می کنند، و کمتر از ۴۵ سال یا بیشتر از ۶۵ سال دارند، آمار بیشتری ثبت کرده اند. همچنین خانم هایی که درد آنژینی بعد از تست نداشتند و کمتر از ۴۵ سال یا بیشتر از ۶۵ سال بودند، آمار بالاتری برای ثبت دارند. البته این آمار برای افراد ۴۵ تا ۶۵ سال هم بالا است اما از آن دو بازه ی سنی کمتر است.

14) سن، میزان کلسترول و فشار خون

Age Group, Cholesterol and Blood Pressure by Heart Disease Status



در این نمودار، دو توده را مشخص کردم که در هر دو توده، تعداد بیماران از موقعی که سطح کلسترول از حد نرمال بیشتر می رود و در محدوده ی بالای 200 قرار دارد، افزایش میابد.

توده ی سمت چپ مربوط به افراد ۴۰ تا ۵۰ سال است که فشار خون پایین تری دارند. توده ی سمت راست برای افرادی است که ۵۰ تا ۶۰ سال دارند و فشار خون بالای 120 را ثبت کرده اند که نشان می دهد در این محدوده ی سنی فشار خون نیز به عاملی مهم تبدیل می شود.

یافته ها

- ❖ بعد از بررسی تمام پارامتر ها مشاهده شد که در این مجموعه داده، نرخ مشاهده شده بیماری در زنان بالاتر از مردان بود. با توجه به تفاوت اندازه گروه های جنسیتی و ماهیت اکتشافی تحلیل، این مشاهده به تنهایی قابل تعمیم به جمعیت عمومی نیست.
- ❖ در افرادی که زیر 45 سال هستند و درد غیر تیپیک دارند، نرخ بیماری بیشتری مشاهده شد.
- ❖ در این مجموعه داده، نسبت موارد مبتلا به بیماری، در گروه کلسترول بالاتر از 200، حدوداً سه برابر گروه مرجع مشاهده شد (از لحاظ تعداد ابتلا). این آمار برای افراد کمتر از 45 سال بیشتر است.
- ❖ برای افرادی که دارای درد آنژینی بعد از تست هستند و دارای تجربه درد غیر تیپیک هستند، نرخ بالای بیماری مشاهده شد.
- ❖ آقایانی که تجربه ی درد در قفسه ی سینه نداشتند، اما در تست ورزش دچار درد آنژینی شدند، آمار بیشتری در بروز بیماری داشتند.
- ❖ در تحلیل این مجموعه داده، الگوی ارتباط میزان کلسترول با وجود بیماری، برجسته تر از الگوی فشار خون است.

سایر توضیحات

- مجموع تحلیل‌ها نشان می‌دهد که بیماری قلبی در این مجموعه داده با یک ویژگی واحد قابل توضیح نیست.
- ویژگی‌هایی مانند سن، نوع درد قفسه سینه و آنژین ناشی از ورزش، الگوهای متفاوتی را میان گروه‌های دارای بیماری و فاقد بیماری نشان می‌دهند.
- بنابراین بررسی همزمان چند ویژگی می‌تواند دید دقیق‌تری نسبت به ساختار داده ایجاد کند.
- در برخی زیرگروه‌های کوچک، نرخ مشاهده شده بیماری به 100٪ رسید. با توجه به تعداد محدود نمونه‌ها در این ترکیب‌ها، این نتایج باید با احتیاط تفسیر شوند و نمی‌توان آنها را به عنوان یک رابطه قطعی یا قابل تعمیم در نظر گرفت.
- تفاوت مشاهده شده در متغیرهایی مانند سن یا نوع درد قفسه سینه می‌تواند نشان‌دهنده ارتباط این ویژگی‌ها با وضعیت بیماری باشد.
- با این حال، از آنجا که این پروژه یک تحلیل اکتشافی است، نمی‌توان صرفاً بر اساس نمودارها نتیجه گرفت که یک ویژگی باعث ایجاد بیماری قلبی شده است.
- برای بررسی دقیق‌تر می‌توان در مراحل بعدی از روش‌های آماری و مدل‌های یادگیری ماشین استفاده کرد.

محدودیت‌ها

این تحلیل دارای محدودیت‌هایی است:

- داده مورد استفاده ممکن است نماینده تمام جمعیت نباشد.
- آمار در مواقعی، مخصوصاً تحلیل‌های ترکیبی دارای کمبود بود؛ با توجه به این موضوع که بخشی از رکوردها به دلیل تکراری بودن، حذف شدند.
- مشاهده‌ی همبستگی یا ارتباط به معنای رابطه علت و معلولی نیست.
- برخی متغیرها به صورت عددی کدگذاری شده‌اند و باید هنگام تحلیل ماهیت واقعی آنها در نظر گرفته شود.
- نتایج این تحلیل به تنهایی برای تصمیم‌گیری پزشکی قابل استفاده نیستند.
- برای بررسی دقیق‌تر اهمیت ویژگی‌ها، تحلیل‌های آماری و مدل‌سازی می‌تواند در مراحل بعدی انجام شود.

نتیجه گیری

هدف این پروژه بررسی ساختار و الگوهای موجود در مجموعه داده بیماری قلبی بود.

پس از انجام مراحل Data Understanding، Data Cleaning و Exploratory Data Analysis، مشخص شد که برخی ویژگی‌ها از جمله سن، نوع درد

قفسه سینه و آنژین ناشی از ورزش الگوهای متفاوتی را میان افراد دارای بیماری قلبی و فاقد بیماری نشان می‌دهند.

همچنین تحلیل چندمتغیره نشان داد که بررسی همزمان ویژگی‌ها می‌تواند اطلاعات بیشتری نسبت به بررسی مستقل آنها ارائه کند.

این تحلیل اکتشافی می‌تواند به عنوان مرحله‌ای اولیه برای تحلیل آماری عمیق‌تر و توسعه مدل‌های پیش‌بینی بیماری قلبی مورد استفاده قرار گیرد.

به طور کلی، در این مجموعه داده الگوهای متفاوتی میان وضعیت بیماری و ویژگی‌هایی مانند سن، نوع درد قفسه سینه، کلسترول و آنژین ناشی از ورزش

مشاهده شد؛ با این حال، شدت و اعتبار این روابط بدون آزمون‌های آماری یا مدل‌سازی قابل تعیین نیست.

منابع

Data Source

- Kaggle dataset(Heart Disease Data)
<https://www.kaggle.com/datasets/johnsmith88/heart-disease-dataset>

Documentation

- Pandas
<https://pandas.pydata.org/docs>
- Matplotlib
https://matplotlib.org/stable/gallery/subplots_axes_and_figures/subplots_demo.html

Report Writing References

- Report Structure
<https://www.sona.com/blog/how-to-write-a-report-for-data-analysis-tips-and-best-practices>
<https://dashthis.com/blog/data-analysis-report>
<https://www.geeksforgeeks.org/data-analysis/how-to-write-data-analysis-reports>
<https://www.zemith.com/en/blogs/data-analysis-and-report>

